

## Fiche de théorie 11

### Linéarité du gradient et du hessien et règle de chaîne

Soit  $f, g : \mathbb{R}^n \rightarrow \mathbb{R}$  des fonctions et soit  $H_f(\mathbf{x})$  désigner son Hessien.

Puisque la dérivée est linéaire ( $(f+g)' = f' + g'$ ), nous avons la règle suivante, qui simplifie la recherche de gradients et de Hessians :

$$\begin{aligned}\text{grad}(f(\mathbf{x}) + g(\mathbf{x})) &= \text{grad } f(\mathbf{x}) + \text{grad } g(\mathbf{x}) \\ H_{f+g}(\mathbf{x}) &= H_f(\mathbf{x}) + H_g(\mathbf{x})\end{aligned}$$

Si  $h : \mathbb{R} \rightarrow \mathbb{R}$  est une autre fonction et que nous considérons la composition  $h(f(\mathbf{x}))$ , alors par la règle de chaîne habituelle ( $(h(f(x)))' = h'(f(x)) f'(x)$ ) nous avons que la même chose vaut pour le gradient :

$$\text{grad } h(f(\mathbf{x})) = h'(f(\mathbf{x})) \text{ grad } f(\mathbf{x}).$$

Ces règles sont simples, mais très utiles.

**Exemple 1.**  $\text{grad}(f(\mathbf{x}))^4 = 4f(\mathbf{x})^3 \text{ grad } f(\mathbf{x})$ .

### Gradient et Hessien d'une fonction quadratique

Considérons  $A \in M_{2,2}$  symétrique,  $\mathbf{b} \in \mathbb{R}^2$  et la quadratique fonction

$$f(x_1, x_2) = \mathbf{x}^\top A \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c = a_{11}x_1^2 + 2a_{12}x_1x_2 + a_{22}x_2^2 + b_1x_1 + b_2x_2 + c.$$

Alors

$$\text{grad } f(x_1, x_2) = \begin{pmatrix} f'_{x_1} \\ f'_{x_2} \end{pmatrix} = \begin{pmatrix} 2a_{11}x_1 + 2a_{12}x_2 + b_1 \\ 2a_{12}x_1 + 2a_{22}x_2 + b_2 \end{pmatrix}.$$

Notons que ceci peut être écrit comme

$$\text{grad } f(x_1, x_2) = 2 \begin{pmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = 2A\mathbf{x} + \mathbf{b}.$$

En fait, les mêmes formules valent dans les dimensions supérieures :

**Théorème 1.** Si  $A \in M_{n,n}$  et  $\mathbf{b} \in \mathbb{R}^n$ , nous avons

$$\text{grad } \mathbf{x}^\top A \mathbf{x} = 2A\mathbf{x} \quad \text{and} \quad \text{grad } \mathbf{b}^\top \mathbf{x} = \mathbf{b}.$$

*Proof.* We have

$$\text{grad } \mathbf{x}^\top A \mathbf{x} = \text{grad} \sum_{i,j=1}^n a_{ij} x_i x_j = \sum_{i,j=1}^n a_{ij} \text{grad } x_i x_j,$$

so we only need to calculate  $\text{grad } x_i x_j$ :

$$\text{grad } x_i x_j = x_i \mathbf{e}_j + x_j \mathbf{e}_i,$$

where  $\mathbf{e}_i$  is a vector of zeroes with 1 at  $i^{\text{th}}$  row. Hence,

$$\text{grad } \mathbf{x}^\top A \mathbf{x} = \sum_{i,j=1}^n a_{ij} (x_i \mathbf{e}_j + x_j \mathbf{e}_i) = \sum_{i,j=1}^n a_{ij} x_i \mathbf{e}_j + \sum_{i,j=1}^n a_{ij} x_j \mathbf{e}_i.$$

Since  $a_{ij} = a_{ji}$  by symmetry of  $A$ , we have

$$\sum_{i,j=1}^n a_{ji} x_i \mathbf{e}_j = \sum_{i,j=1}^n a_{ij} x_j \mathbf{e}_i = A \mathbf{x},$$

which concludes the proof of the first claim. The second claim follows similarly:

$$\text{grad } \mathbf{b}^\top \mathbf{x} = \text{grad} \sum_{i=1}^n b_i x_i = \sum_{i=1}^n b_i \text{grad } x_i = \sum_{i=1}^n b_i \mathbf{e}_i = \mathbf{b},$$

where we used that  $\text{grad } x_i = \mathbf{e}_i$ . □

Donc,

$$\boxed{\text{grad}(\mathbf{x}^\top A \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c) = 2A \mathbf{x} + \mathbf{b}.}$$

Nous allons utiliser ceci plus tard.

**Remarque 1.** Compare this with  $\frac{d}{dx}(ax^2 + bx + c) = 2ax + b$ .

Ensuite, nous voulons calculer le Hessien de la fonction quadratique. Puisque le Hessien est linéaire et les dérivées secondes de  $\mathbf{b}^\top \mathbf{x} + c$  sont clairement nulles, nous avons seulement besoin de trouver le Hessien de  $\mathbf{x}^\top A \mathbf{x}$ . UNE calcul similaire donne

$$\boxed{H_f(\mathbf{x}) = 2A.}$$

Par conséquent, nous savons comment trouver à la fois le gradient et le Hessien d'une fonction !

## Régression linéaire

Considérons le problème suivant : nous avons des points  $x_i$  et  $y_i$ ,  $i = 1, \dots, n$  obtenus à partir de certaines données. Nous traçons ces points et voyons qu'ils se situent près d'une droite. Comment trouver la meilleure droite qui correspond à ces points ?

Une droite sur le plan peut être exprimée par l'équation suivante :

$$y = ax + b.$$

Nous ne pouvons pas simplement supposer que  $y_i = ax_i + b$  pour tout  $i = 1, \dots, n$  et essayer de résoudre  $a, b$ , car ce serait trop d'équations. Autrement dit, à moins qu'ils ne se situent tous exactement sur la même ligne pour commencer.

Ce que nous pouvons faire à la place est de supposer que  $y_i = ax_i + b + \varepsilon_i$ , où  $\varepsilon_i$  sont des erreurs. Maintenant, nous pouvons trouver  $a$  et  $b$ , qui minimisent l'erreur totale.

Mais qu'entendons-nous par erreur totale ? Il existe de nombreuses façons d'y répondre, le plus standard est donné par la somme des erreurs au carré :

$$R = \sum_{i=1}^n \varepsilon_i^2.$$

En branchant  $\varepsilon_i = y_i - ax_i - b$  dans cette formule, nous voyons que  $R$  est une fonction de  $a$  et  $b$  :

$$R(a, b) = \sum_{i=1}^n (y_i - ax_i - b)^2.$$

Nous pouvons maintenant minimiser cette fonction par rapport à  $a$  et  $b$  et obtenir la droite dite de régression des moindres carrés.

**Remarque 2.** Ceci est de loin la seule façon de définir ce que "meilleure ligne" signifie dans ce contexte. Une autre alternative tout aussi intéressante consiste à minimiser

$$L(a, b) = \sum_{i=1}^n |\varepsilon_i| = \sum_{i=1}^n |y_i - ax_i - b|.$$

Ceci est connu comme régression linéaire robuste. Malheureusement,  $|x|$  est non différentiable, donc la minimisation dans ce cas devient plus complexe.

Pour minimiser  $R$ , nous calculons d'abord son gradient :

$$\text{grad } R(a, b) = \begin{pmatrix} R_a \\ R_b \end{pmatrix} = \begin{pmatrix} -2 \sum_{i=1}^n (y_i - ax_i - b)x_i \\ -2 \sum_{i=1}^n (y_i - ax_i - b) \end{pmatrix},$$

égalons-le à zéro et obtenons deux équations :

$$\sum_{i=1}^n y_i x_i - a \sum_{i=1}^n x_i^2 - b \sum_{i=1}^n x_i = 0 \quad \text{and} \quad \sum_{i=1}^n y_i - a \sum_{i=1}^n x_i - bn = 0.$$

En notant

$$\rho = \frac{1}{n} \sum_{i=1}^n y_i x_i, \quad s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2, \quad \mu_x = \frac{1}{n} \sum_{i=1}^n x_i, \quad \mu_y = \frac{1}{n} \sum_{i=1}^n y_i,$$

nous trouvons que les équations ci-dessus peuvent être réécrites comme

$$\begin{cases} \rho - as^2 - b\mu_x = 0, \\ \mu_y - a\mu_x - b = 0. \end{cases}$$

En résolvant ce système, nous obtenons

$$a = \frac{\rho - \mu_x \mu_y}{s^2 - \mu_x^2}, \quad b = \mu_y + a\mu_x.$$

Si nous branchons  $\rho$ ,  $\mu_x$ ,  $\mu_y$  et  $s^2$ , nous obtiendrons

$$a = \frac{\frac{1}{n} \sum_{i=1}^n y_i x_i - \frac{1}{n^2} \sum_{i=1}^n x_i \sum_{j=1}^n y_j}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \left( \frac{1}{n} \sum_{i=1}^n x_i \right)^2}$$

Nous pouvons aussi remanier un peu cette formule et la réécrire sous une autre forme :

$$a = \frac{\sum_{i=1}^n (x_i - \mu_x)(y_i - \mu_y)}{\sum_{i=1}^n (x_i - \mu_x)^2}.$$

Rappelons toutefois qu'il s'agit de points candidats, et nous devons vérifier qu'ils minimisent effectivement  $R$ . À cette fin, nous calculons le Hessien de  $R$  :

$$H_R(\mathbf{x}) = \begin{pmatrix} 2 \sum_{i=1}^n x_i^2 & 2 \sum_{i=1}^n x_i \\ 2 \sum_{i=1}^n x_i & 2n \end{pmatrix}.$$

Clairement,

$$2 \sum_{i=1}^n x_i^2 > 0,$$

nous devons donc vérifier le déterminant et appliquer la loi d'inertie de Sylvester. Nous avons

$$\begin{aligned} \det H_R(\mathbf{x}) &= 4n \sum_{i=1}^n x_i^2 - 4 \left( \sum_{i=1}^n x_i \right)^2 \\ &= 4n^2 \left( \frac{1}{n} \sum_{i=1}^n x_i^2 - \left( \frac{1}{n^2} \sum_{i=1}^n x_i \right)^2 \right) \\ &= 4n \sum_{i=1}^n (x_i - \mu_x)^2 > 0. \end{aligned}$$

**Remarque 3.** Ci-dessus, nous avons utilisé le calcul suivant :

$$\begin{aligned}
\sum_i (x_i - \mu_x)^2 &= \sum_i (x_i^2 - 2x_i\mu_x + \mu_x^2) \\
&= \sum_i x_i^2 - 2\mu_x \sum_i x_i + n\mu_x^2 \\
&= \sum_i x_i^2 - 2n\mu_x^2 + n\mu_x^2 \\
&= \sum_i x_i^2 - n\mu_x^2.
\end{aligned}$$

## Régression linéaire sous forme matricielle

Résolvons le même problème en utilisant la notation matricielle. Nous verrons alors que cette approche permet de réaliser des types de régression beaucoup plus généraux !

Soit  $y_i$  et  $x_i$ ,  $i = 1, \dots, n$  nos points de données. Notons

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} b \\ a \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \mathbf{y} - X\boldsymbol{\beta}.$$

Notons que  $X$  est une matrice  $n \times 2$ . La même fonction  $R$  comme ci-dessus dans cette notation peut être écrite comme

$$R(\boldsymbol{\beta}) = \boldsymbol{\varepsilon}^\top \boldsymbol{\varepsilon}.$$

En branchant la définition de  $\boldsymbol{\varepsilon}$ , nous obtenons

$$R(\boldsymbol{\beta}) = (\mathbf{y} - X\boldsymbol{\beta})^\top (\mathbf{y} - X\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - \boldsymbol{\beta}^\top X^\top \mathbf{y} - \mathbf{y}^\top X\boldsymbol{\beta} + \boldsymbol{\beta}^\top X^\top X\boldsymbol{\beta}.$$

Puisque  $\mathbf{y}^\top X\boldsymbol{\beta} = \boldsymbol{\beta}^\top X^\top \mathbf{y}$  (nous pouvons toujours transposer un nombre !), nous avons

$$R(\boldsymbol{\beta}) = \boldsymbol{\beta}^\top A\boldsymbol{\beta} - 2\mathbf{b}^\top \boldsymbol{\beta} + c,$$

où  $A = X^\top X$ ,  $\mathbf{b} = X^\top \mathbf{y}$  et  $c = \mathbf{y}^\top \mathbf{y}$ .

Selon le théorème au début de ce cours, le gradient de  $R$  est donné par

$$\text{grad } R(\boldsymbol{\beta}) = 2A\boldsymbol{\beta} - 2\mathbf{b}.$$

En l'égalant à zéro, nous constatons que  $\boldsymbol{\beta}$  satisfait

$$A\boldsymbol{\beta} - \mathbf{b} = \mathbf{0}.$$

Donc,

$$\boldsymbol{\beta} = A^{-1}\mathbf{b}.$$

Il reste à brancher les formules pour  $A$  et  $\mathbf{b}$  pour obtenir

$$\boxed{\boldsymbol{\beta} = (X^\top X)^{-1} X^\top \mathbf{y}.}$$

Cette formule est appelée l'équation normale de la régression linéaire, elle donne les coefficients de régression linéaire directement en fonction des données d'origine points !

**Remarque 4.** Note that if  $\mathbf{y} \in \mathbb{R}^n$  and  $X \in M_{n,2}$ , then  $X^\top \in M_{2,n}$ , hence  $X^\top \mathbf{y} \in \mathbb{R}^2$  and  $X^\top X \in M_{2,2}$ , so all products are well-defined.

The matrix  $X^\top X$  is strictly positive definite, which means that it does not have zero eigenvalues, which means that it is invertible!

**Remarque 5** (Important). Note that we cannot simplify  $(X^\top X)^{-1} X^\top$  using  $(AB)^{-1} = B^{-1}A^{-1}$ . Why? Because the last formula is only true if  $A$  and  $B$  are invertible. In particular, they must be square! Note that although  $X^\top X$  is a square matrix ( $2 \times 2$ ),  $X$  and  $X^\top$  are not (they are  $n \times 2$  and  $2 \times n$  correspondingly). Hence, their inverses do not even make sense!

## Comment utiliser l'équation normale en pratique ?

Après avoir dérivé l'équation normale, nous pouvons oublier sa dérivation et simplement l'utiliser comme suit :

- Étant donné les points de données  $x_i, y_i, i = 1, \dots, n$ , construire un vecteur  $\mathbf{y}$  et une matrice  $X$  comme ci-dessus.
- Calculer  $\boldsymbol{\beta} = (X^\top X)^{-1} X^\top \mathbf{y}$ .
- Maintenant, la meilleure droite qui approche nos points de données est donnée par  $y = \beta_1 + \beta_2 x$ .

## Régression linéaire généralisée

Que faire si nous voulons trouver la meilleure courbe, au lieu d'une droite, qui approxime notre ensemble de données  $x_i, y_i$ ? Par exemple, nous pouvons trouver une courbe polynomiale approximant nos données :

$$y_i \approx \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_p x_i^p$$

en utilisant la même idée ! À cette fin, nous construisons l'erreur d'approximation

$$R(\boldsymbol{\beta}) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i - \dots - \beta_p x_i^p)^2$$

et minimisons-le par rapport à  $\boldsymbol{\beta}$ . Ceci devient beaucoup plus facile dans la notation matricielle. Soit

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^p \\ 1 & x_2 & x_2^2 & \dots & x_2^p \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^p \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}.$$

Avec cette notation,  $R$  devient

$$R(\boldsymbol{\beta}) = (\mathbf{y} - X\boldsymbol{\beta})^\top (\mathbf{y} - X\boldsymbol{\beta}).$$

Notons que le problème est nettement plus général (polynomial au lieu de droite), mais la fonction que nous devons optimiser est exactement la même !

Par conséquent, nous pouvons immédiatement écrire la solution de ce problème de minimisation, c'est-à-dire, l'équation normale :

$$\boldsymbol{\beta} = (X^\top X)^{-1} X^\top \mathbf{y}.$$

Cette équation nous indique maintenant que la meilleure courbe polynomiale qui approxime nos données est donnée par

$$y = \beta_0 + \beta_1 x + \cdots + \beta_p x^p.$$

**Remarque 6.** *In fact, there is nothing special about polynomials. We can approximate our data by a linear combination of any functions:*

$$y_i \approx \sum_{k=1}^p \beta_k \varphi_k(x_i).$$

To this end, we just change the definition of the matrix  $X$  to

$$X = \begin{pmatrix} \varphi_0(x_1) & \varphi_1(x_1) & \dots & \varphi_p(x_1) \\ \varphi_0(x_2) & \varphi_1(x_2) & \dots & \varphi_p(x_2) \\ \vdots & \vdots & \vdots & \vdots \\ \varphi_0(x_n) & \varphi_1(x_n) & \dots & \varphi_p(x_n) \end{pmatrix},$$

and use the same normal equation with this new matrix  $X$ . One neat example is to approximate seasonal data with periodic functions:

$$y_i \approx \beta_0 + \beta_1 \cos\left(\frac{x_i}{T_1}\right) + \beta_2 \cos\left(\frac{x_i}{T_2}\right),$$

where  $x_i$  is interpreted as time and  $T_1, T_2$  are two different time scales.

## Une autre extension naturelle

Une autre extension naturelle de la méthode précédente se produit lorsque nous voulons modéliser l'effet de nombreux facteurs  $x_i, z_i, t_i, \dots$  sur  $y_i$ . Géométriquement, cela signifie que nous essayons de trouver le meilleur hyperplan pour approximer nos points.

Supposons que  $y_i \approx \beta_0 + \beta_1 x_i + \beta_2 z_i$  (seulement deux facteurs). Alors l'erreur de cette approximation est

$$R(\boldsymbol{\beta}) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i - \beta_2 z_i)^2,$$

qui peut à nouveau être écrite de la même manière avec la seule différence que  $X$  est maintenant

$$X = \begin{pmatrix} 1 & x_1 & z_1 \\ 1 & x_2 & z_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & z_n \end{pmatrix}.$$

Tout le reste dans le modèle reste le même, donc le  $\boldsymbol{\beta}$  résultant est à nouveau donné par l'équation normale.